# Параллельное программирование (параллельные алгоритмы)

Лисицын Сергей ФРКТ МФТИ 2018 г.

# Программа 1 семестра

513 группа

Занятия: 07.02, 21.02, 7.03,

21.03, 04.04, 18.04, 2.05

Зачёт: 16.05

516 группа

Занятия: 14.02, 28.02, 14.03,

28.03, 11.04, 25.04, 9.05

Зачёт: 23.05

	9 <sup>00</sup> - 10 <sup>25</sup>		Операционные системы/ 802 КПМ												
	10 <sup>45</sup> - 12 <sup>10</sup>	Выч.математика 705 КПМ	MUSKVINTVDA MUSKVINTVDA MUSKVINTVDA							Операционные системы/ 702 КПМ					
13	12 <sup>20</sup> - 13 <sup>45</sup>		Выч.математика 705 КПМ	401411				Квант.механика 514 ГК							
	13 <sup>55</sup> - 15 <sup>20</sup>	Вычислительная математика/ Доцент Барабанщиков А.В./ Актовый зал													
S	15 <sup>30</sup> - 16 <sup>55</sup>	Ин.яз.	Ин.яз.	Ин.яз.	Ин.яз.	Ин.яз.	Ин.яз.	Ин.яз.	Ин.яз.	Ин.яз.					
	17 <sup>05</sup> - 18 <sup>30</sup>	Параллельное программирование/ Члкорр. РАН Якобовский М.В./ Б.Хим.													
	18 <sup>35</sup> - 20 <sup>00</sup>			паралл.програм. (неч.нед.) 801 илм			Паралл.програм. (чет.нед.) 801 КПМ		паралл.прогр. (неч.нед.)804 илм	Паралл.програм. (чет.нед.) 804 КПМ					

# Программа 1 семестра

#### 6 семинаров\*:

- 1. Вводная лекция
- 2. Программирование на MPI
- 3. Статическая балансировка
- 4. Динамическая балансировка
- 5. Стандарт POSIX Threads
- 6. Программирование на общей памяти

Февраль		Март					Апрель				Май				Июнь			
5-11 фев	12-18 фев	19-25 фев	26 фев-4 мар	5-11map	12-18 мар	19-25мар	26 мар - 1 апр	2-8 апр	9-15 апр	16-22 апр	23-29апр	30 апр - 6 май	7-13 май	14-20 май	21-27 май	28 май - 3 июн	4-10 июн	11-17 июн
24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39	40	41	42
	Б	ака	лав	риа	Т													
															3	Э	Э	Э
															3	Э	Э	Э
														3	3	Э	Э	Э
															3	Э	Э	Э

<sup>\*</sup>план может быть изменён

# Программа 1 семестра

#### Программы:

- Обязательные задачи (4)
- Бонусные задачи (3)

#### Оценка за семестр:


- +5: Лекционная контрольная
- +2: Посещения/3
- +2: Мгновенные обязательные задачи/2
- +3: Бонусные задачи


## Perf = Freq\*IPC/IC

- Конвейеризация вычислений (1970-е) микроуровневый параллелизм
- Дублирование вычислителей (1980-е) параллелизм уровня команд (векторизация, VLIW)
- Дублирование "конвейеров" (2000-е)- параллелизм уровня потоков/заданий

Таксономия (Классификация) Флинна (1966)

- SISD: компьютер фон-Неймановской архитектуры
- SIMD: векторные процессоры (MMX, SSE), матричные процессоры и процессоры с архитектурой VLIW.
- MISD: не используется
- MIMD:
  - Общая память Symmetric Multiprocessor SMP Разделенная память Massively Parallel Processing MPP -> Кластерные системы





# Симметричное мультипроцессирование

- 1. Несколько однородных процессоров и массив общей памяти
- 2. Когерентность кэшей, урегулирование доступа к памяти
- 3. Ограниченная масштабируемость
- 4. Работает под единой ОС
- 5. Модель программирования: Потоки (pthread, OpenMP)

#### Массивно-параллельные системы

- 1. Вычислительные узлы и коммуникационная среда
- 2. Закрытая локальная память
- 3. Масштабируемость ~не ограниченная
- 4. Полная ОС на управляющей машине, на узлах урезанная версия
- 5. Модель программирования: Модель передачи сообщений ("fork", MPI, PVM, BSPlib)

#### Метрики параллелизма

- Доля последовательных операций:  $\alpha = \frac{IC_{\parallel}}{(IC_{\parallel} + IC_{\parallel})}$
- Время на р потоках:  $T_p = \alpha T_1 + \frac{(1-\alpha)T_1}{p}$
- Ускорение:  $S = T_1/T_p$
- Эффективность: E = S/p

#### Закон Амдала

$$S = \frac{T_1}{T_p} = \frac{T_1}{\alpha T_1 + \frac{(1 - \alpha)T_1}{p}} \le \frac{1}{\alpha}$$



Message Passing Interface

**Параллельная программа** - множество одновременно выполняемых **процессов**.

Каждый процесс порождается на основе одного и того же программного кода (fork).

Количество процессов определяется в момент запуска программы.

Все процессы последовательно пронумерованы от 0 до **p-1** (ранг процесса), где **p** есть общее количество процессов.

• Подключение библиотеки:

```
#include "mpi.h"
```

• Начало работы МРІ:

```
int MPI_Init ( int *agrc,
char ***argv );
```

• Завершение работы:

```
MPI_Finalize();
```

Функции **MPI\_Init** и **MPI\_Finalize** являются обязательными и должны быть выполнены (только один раз) каждым процессом параллельной программы.

Компиляция программы:

трісс -о <исполняемый файл> <исходный файл>.с

# Запуск: mpirun -n <число процессов> <исполняемый файл> [аргументы]

```
#include <stdio.h>
#include <mpi.h>
int main(int argc, char* argv[])
    int ProcRank;
    MPI Init(&argc, &argv);
    MPI Comm rank (MPI COMM WORLD, & ProcRank);
    printf("Hello from process %d\n", ProcRank);
    MPI Finalize();
    return 0;
    mpicc -o hello main.c
   mpirun -n 4 hello
```

• Определение количества процессов int MPI Comm size ( MPI Comm comm, int \*size ); • Определения ранга процесса int MPI Comm rank ( MPI Comm comm, int \*rank ) #include "mpi.h" int main ( int argc, char \*argv[] ) int ProcNum, ProcRank; <программный код без использования MPI функций> MPI Init ( &agrc, &argv ); MPI Comm size ( MPI COMM WORLD, &ProcNum); MPI Comm rank ( MPI COMM WORLD, &ProcRank);

MPI Finalize();

return 0;

<программный код с использованием MPI функций>

<программный код без использования MPI функций>

12

Коммуникатор - служебный объект, объединяющий в своем составе группу процессов и контекст, используемый при передачи данных.

Все процессы входят в состав создаваемого по умолчанию коммуникатора с идентификатором MPI\_COMM\_WORLD.

MPI\_Comm comm = MPI\_COMM\_WORLD;

Операции передачи сообщений:

• Парные (point-to-point) – операции между двумя процессами MPI\_Send, MPI\_Recv...

• Коллективные (collective) – коммуникационные действия для **одновременного** взаимодействия нескольких процессов MPI Bcast, MPI Reduce...

#### Базовые типы

MPI_Datatype	C Datatype
MPI_BYTE	
MPI_CHAR	signed char
MPI_DOUBLE	Double
MPI_FLOAT	Float
MPI_INT	Int
MPI_LONG	Long
MPI_LONG_DOUBLE	long double
MPI_PACKED	
MPI_SHORT	short
MPI_UNSIGNED_CHAR	unsigned char
MPI_UNSIGNED	unsigned int
MPI_UNSIGNED_LONG	unsigned long
MPI_UNSIGNED_SHORT	unsigned short

#### Производные типы

• Функции создания типа

MPI\_Type\_contiguous

MPI\_Type\_vector

MPI\_Type\_hvector

MPI\_Type\_indexed

MPI\_Type\_hindexed

MPI\_Type\_struct

• Функция регистрации типа

```
int MPI_Type_commit
(MPI_Datatype *datatype);
```

#### Передача сообщений:

```
int MPI_Send(void *buf, int count,
MPI_Datatype type, int dest, int tag,
MPI_Comm comm);
```

#### Приём сообщений:

```
int MPI_Recv(void *buf, int count,
MPI_Datatype type, int source, int tag,
MPI_Comm comm, MPI_Status *status);
```

MPI\_ANY\_SOURCE
MPI\_ANY\_TAG
MPI\_COMM\_WORLD

buf – адрес буфера с данными отправляемого сообщения.

count – количество элементов данных в сообщении.

type - тип элементов данных пересылаемого сообщения.

dest - ранг процесса, которому отправляется сообщение.

source - ранг процесса, от которого должен быть выполнен прием сообщения.

tag - значение-тег, используемое для идентификации сообщений.

comm - коммуникатор, в рамках которого выполняется передача данных.

status — указатель на структуру данных с информацией о результате выполнения операции.

```
#include <stdio.h>
#include <mpi.h>
int main(int argc, char* argv[])
    int ProcNum, ProcRank, RecvRank;
    MPI Status Status;
    MPI Init(&argc, &argv);
    MPI Comm size (MPI COMM WORLD, & ProcNum);
    MPI Comm rank (MPI COMM WORLD, & ProcRank);
    if ( ProcRank == 0 )
        /// Лействия, выполняемые только процессом с рангом 0
        printf ("\n Hello from process %d", ProcRank);
        for ( int i = 1; i < ProcNum; i++ )</pre>
            MPI Recv(&RecvRank, 1, MPI INT, MPI ANY SOURCE,
            MPI ANY TAG, MPI COMM WORLD, &Status);
            printf("\n Hello from process %d", RecvRank);
    } else {
        /// Сообщение, отправляемое всеми процессами,
        /// кроме процесса с рангом 0
        MPI Send(&ProcRank, 1, MPI INT, 0, 0, MPI COMM WORLD);
    MPI Finalize();
    return 0;
```

Описание всех функций:


https://www.open-mpi.org/doc/current/

Подробное описание МРІ на русском:

http://rsusu1.rnd.runnet.ru/tutor/method/m2/content.html

```
Измерение времени:
double MPI Wtime (void);
Измерение точности измерения времени:
double MPI Wtick (void);
Синхронизация процессов:
int MPI Barrier (MPI Comm comm);
```

```
#include <stdio.h>
#include <mpi.h>
int main(int argc, char** argv)
 int rank = 0, size = 0;
 double start time = 0, end time = 0;
 MPI Init(&argc, &argv);
 MPI Comm rank (MPI COMM WORLD, &rank);
 MPI Comm size (MPI COMM WORLD, &size);
 MPI Barrier (MPI COMM WORLD);
 if (rank == 0)
    start time = MPI Wtime();
  /// AJPODUTM, BDSMS KOTODOPO MSMEDSEM
 MPI Barrier (MPI COMM WORLD);
 if (rank == 0)
   end time = MPI_Wtime();
 if (rank == 0)
   printf("[TIME] %lf\n", end time - start time);
 MPI Finalize();
 return 0;
```




int MPI\_Bcast(void \*buf,int count,MPI\_Datatype
type, int root,MPI\_Comm comm)

**buf** – буфер памяти с отправляемым сообщением (для процесса с рангом 0), и для приема сообщений для всех остальных процессов

root – ранг процесса, выполняющего рассылку данных

Сбор данных с операцией

$$y_j = \bigotimes_{i=0}^{n-1} x_{ij}, 0 \le j < n$$



процессы

int MPI\_Reduce(void \*sendbuf, void \*recvbuf,int
count, MPI\_Datatype type, MPI\_Op op,int root,MPI\_Comm
comm)


- sendbuf - буфер памяти с отправляемым сообщением

процессы

- recvbuf буфер памяти для результирующего сообщения (только для процесса с рангом root)
- ор
   ор
   операция, которая должна быть выполнена над данными
- root
   ранг процесса, на котором должен быть получен результат

Операция	Описание
MPI_MAX	Определение максимального значения
MPI_MIN	Определение минимального значения
MPI_SUM	Определение суммы значений
MPI_PROD	Определение произведения значений
MPI_LAND	Выполнение логической операции "И" над значениями сообщений
MPI_BAND	Выполнение битовой операции "И" над значениями сообщений
MPI_LOR	Выполнение логической операции "ИЛИ" над значениями сообщений
MPI_BOR	Выполнение битовой операции "ИЛИ" над значениями сообщений
MPI_LXOR	Выполнение логической операции исключающего "ИЛИ" над значениями сообщений
MPI_BXOR	Выполнение битовой операции исключающего "ИЛИ" над значениями сообщений
MPI_MAXLOC	Определение максимальных значений и их индексов
MPI_MINLOC	Определение минимальных значений и их индексов


Обобщенная передача данных от одного всем



int MPI\_Scatter(void \*sbuf, int scount, MPI\_Datatype stype, void \*rbuf, int rcount, MPI\_Datatype rtype, int root, MPI\_Comm comm)

- sbuf, scount, stype параметры передаваемого сообщения (scount определяет количество элементов, передаваемых на каждый процесс)
- -rbuf, rcount, rtype параметры сообщения, принимаемого в процессах
- root ранг процесса, выполняющего рассылку данных

Обобщенная передача данных от всех одному



int MPI\_Gather(void \*sbuf, int scount, MPI\_Datatype stype, void \*rbuf, int rcount, MPI\_Datatype rtype, int root, MPI Comm comm)

- sbuf, scount, stype параметры передаваемого сообщения,
- rbuf, rcount, rtype параметры принимаемого сообщения,
- root ранг процесса, выполняющего сбор данных,

MPI\_All\* - результат дублируется во всех процессах (MPI\_Allreduce, MPI\_Allgather ...)

MPI\_\*v – размеры передаваемых процессами сообщений могут быть различны (MPI\_Scatterv, MPI\_Allgatherv ...)

Режимы передачи данных:

MPI\_Send – стандартный режим.

MPI\_Ssend – синхронный режим (ждет ответ о приёме сообщения)

MPI\_Rsend – режим передачи по готовности (сработает только при запущенном MPI\_Recv)

MPI\_Bsend – буферизированный режим (использует дополнительный буфер для отправки)


**Блокирующие** функции приостанавливают выполнение процессов до момента завершения работы. (MPI\_\*Send, MPI\_Recv)


```
Неблокирующие функции обмена данными выполняются без блокировки. (MPI_I*send, MPI_Irecv)
int MPI_I*(..., MPI_Request *request);
```

#### Проверка состояния неблокирующей функции:


```
int MPI_Test( MPI_Request *request, int *flag,
MPI_status *status)
-request - дескриптор операции, определенный при вызове неблокирующей функции
-flag - результат проверки (=true, если операция завершена)
-status - результат выполнения операции обмена (только для завершенной операции)
```


MPI Testall - проверка завершения всех перечисленных операций обмена MPI Waitall - ожидание завершения всех операций обмена MPI Testany - проверка завершения хотя бы одной из перечисленных операций обмена MPI Waitany - ожидание завершения любой из перечисленных операций обмена MPI Testsome - проверка завершения каждой из перечисленных операций обмена MPI Waitsome - ожидание завершения хотя бы одной из перечисленных операций обмена и оценка состояния по всем





Стена Фокса (пример с лекций © М.В. Якобовского)





Проблемы балансировки вычислительной нагрузки:

• структура распределенной задачи неоднородна

• структура вычислительного комплекса (например, кластера) неоднородна

• структура межузлового взаимодействия неоднородна


#### Статическая балансировка

- отображение задач до начала выполнения задачи
- борьба с неоднородностями при помощи эвристик и опыта предыдущих запусков

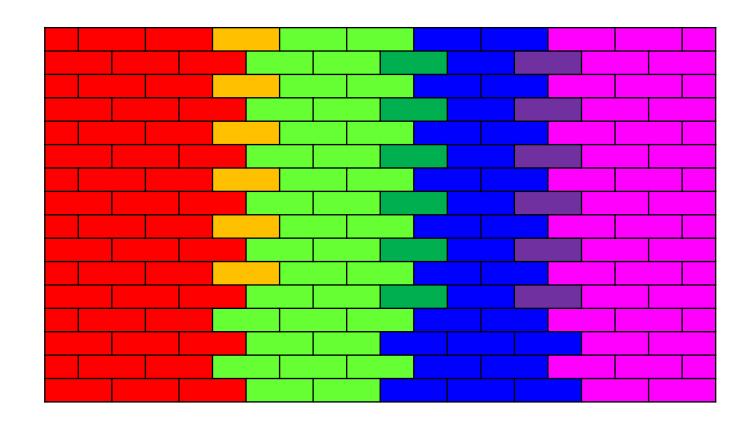
#### Динамическая балансировка

- отображение задач происходит до и во время выполнения задачи
- борьба с неоднородностями при помощи постоянного (пере)распределения задач

## Статическая балансировка



## Динамическая балансировка



подзадачи

••••• результаты


#### Динамическая балансировка

RCL – стратегия переноса нагрузки:

•случайный алгоритм (random, R)

•алгоритм, основанный на коммуникациях (communication, C)

•алгоритм, основанный на вычислении нагрузки (load, L)



Длинная арифметика (сложение)

_	21	43	76	54
+	4	55	24	02
			0-	<b>⊢</b> 56
		1•	<b>— 1</b> 00	
	0	<b>–</b> 99		
	25	99	00	56

Спекулятивные вычисления

	21	43	76	54	53	09	12	94	11	23	08	05
+	4	55	24	45	85	75	25	41	54	25	08	97
			0+	<b>–</b> 99			1-	<b>─ 1</b> 35			1	<del>- 1</del> 02
			1	— <b>1</b> 00			1	<b>— 1</b> 36			1	<del>- 1</del> 02
		1•	<b>- 1</b> 00			0<	<b>—</b> 38			0	<del>-</del> 17	
		1*	<del>- 1</del> 01			0	<del>-</del> 38			0	<del>-</del> 17	
	0+	<b>-</b> 99			0	<b>–</b> 84			0	<b>–</b> 48		
	0+	<b>-</b> 99			0	<del>-</del> 84			0	<del>-</del> 48		
	25				138				65			
	25				<b>1</b> 38				65			
	25	99	00	99	38	84	38	35	65	48	17	02
	25	99	01	00	38	84	38	36	65	48	17	02

Суммирование старших разрядов

+	21	43	76	54	53	09	12	94	11	23	08	05
T	4	55	24	45	85	75	25	41	54	25	80	97
·			0	<b>–</b> 99	<b>1</b> 38		1	<mark>— 1</mark> 35 ॄ	65		1•	<b>— 1</b> 02
			1•	<b>— 1</b> 00	<b>1</b> 37		1	<b>— 1</b> 36	66		1	<b>— 1</b> 02
		1	<b>— 1</b> 00			0	<b>—</b> 38			0•	<b>—</b> 17	
		1	<b>1</b> 01			0	<del>-</del> 38			0	<b>—</b> 17	
	0+	<b>–</b> 99			0<	<b>—</b> 84			0•	<b>–</b> 48		
	0+	<b>-</b> 99			0	<b>—</b> 84			0•	<b>—</b> 48		
	25				<b>1</b> 38				65			
	25				<b>1</b> 38				65			
"	25	99	00	99	38	84	38	35	65	48	17	02
	25	99	01	00	38	84	38	36	65	48	17	02 39

#### Динамическая балансировка

Исполнитель					1	3	3 +	2	1+
Первое число	32 разряда	24 разряда							
Второе число	32 разряда	24 разряда							
Результат (0)							32 разряда		24 разряда
Результат (1)							32 разряда		24 разряда
Перенос разряда (0)							1 разряд		1 разряд
Перенос разряда (1)							1 разряд		1 разряд

### **POSIX Threads**

Процессор Процессор ... Процессор

POSIX – portable operating system interface



6)

Добавление Threads API:

#include <pthread.h>

Компиляция программы:

gcc -o <исполняемый файл> <исходный файл>.c -lpthread

### POSIX Threads

#### Создание потока:

```
int pthread_create(pthread_t *thread, const pthread_attr_t *attr,
void *(*start_routine) (void *), void *arg);
```

Ожидание завершения потока:

int pthread\_join(pthread t thread, void \*\*status);

```
#include <pthread.h>
#include <stdio.h>
void * thread func(int id)
    printf("[Thread] %d\n", id);
    return;
void main(int argc, char **argv)
    pthread t thread1, thread2;
    pthread_create(&thread1, NULL, (void *(*) (void *)) thread_func, (void *) 1);
    pthread create(&thread2, NULL, (void *(*) (void *)) thread func, (void *) 2);
   pthread join(thread1, NULL);
    pthread join(thread2, NULL);
    return;
```

### POSIX Threads + MPI

Компиляция программы:

mpicc -o <исполняемый файл> <исходный файл>.c -lpthread

#### Запуск:

mpirun -n <число процессов>

<исполняемый файл> [аргументы]


```
#include <pthread.h>
#include "mpi.h"
#include <stdio.h>
int rank, size;
void * thread func(int id)
   printf("[Process]%d [Thread] %d\n", rank, id);
   return;
void main(int argc, char **argv)
   pthread t thread1, thread2;
   /// Initialize Mpi Environment.
   MPI Init(&argc, &argv);
   MPI Comm size (MPI COMM WORLD, &size);
   MPI Comm rank (MPI COMM WORLD, &rank);
   pthread create(&thread1, NULL, (void *(*) (void *)) thread func, (void *) 1);
   pthread create(&thread2, NULL, (void *(*) (void *)) thread func, (void *) 2);
   pthread join(thread1, NULL);
   pthread join(thread2, NULL);
   MPI Finalize();
   return;
```

### POSIX Threads + MPI


- Потоки довольно просто обмениваются данными по сравнению с процессами.
- Создавать потоки для ОС проще и быстрее, чем создавать процессы.

- Необходима потоковая безопасность функций. Для процессов это не нужно.
- Один бажный поток может повредить остальные. Процессы более изолированы друг от друга.
- Потоки конкурируют друг с другом в адресном пространстве за стек и локальное хранилище.


Пузырьковая сортировка




Чёт-нечёт перестановка



Сортировка слиянием



#### Сортировка слиянием



Чёт-нечёт слияние

